

**KÁSSIO MARQUES TAVARES**

**PREVISÃO DOS RESULTADOS DO CAMPEONATO  
BRASILEIRO DE FUTEBOL UTILIZANDO REDES  
NEURAIS ARTIFICIAIS**



UNIVERSIDADE FEDERAL DE UBERLÂNDIA  
FACULDADE DE ENGENHARIA MECÂNICA  
2015

**KÁSSIO MARQUES TAVARES**

**PREVISÃO DOS RESULTADOS DO CAMPEONATO BRASILEIRO  
DE FUTEBOL UTILIZANDO REDES NEURAIS ARTIFICIAIS**

Projeto de Fim de Curso apresentado como  
exigência parcial para obtenção do Diploma de  
**BACHAREL EM ENGENHARIA MECATRÔNICA**, pela Universidade Federal de Uberlândia.

Área de concentração: Inteligência Artificial.

Orientador: Prof. PhD. Keiji Yamanaka

Uberlândia - MG

2015

*"Do your best, then don't worry, be happy"*

Meher Baba

## **AGRADECIMENTOS**

Aos meus pais, Alba Luzia Marques e José Humberto Tavares, por todo o apoio oferecido ao longo de toda minha vida.

À toda minha família, que independentemente da distância, sempre estiveram comigo quando precisei.

À Universidade Federal de Uberlândia, à Faculdade de Engenharia Mecânica e ao curso de Engenharia Mecatrônica pela oportunidade de realizar esse curso.

Ao Professor PhD. Keiji Yamanaka pela possibilidade de realizar este projeto, além de toda a orientação, paciência e auxílio oferecidos no decorrer do trabalho.

Aos meus amigos, Alexandre Rodrigues, Bruno Pinheiro, Danilo Andrades, Julianne Rodrigues, Lucas Ferraz, Lucas Lopes, Manoel Martins e, principalmente, à minha namorada Natássia Navarro, por toda a ajuda, direta ou indireta, as quais foram essenciais para a conclusão deste projeto.

À todos que em mim depositaram sua confiança e, mesmo não colaborando diretamente, dirigiram suas boas energias, pensamentos, palavras e intensões em favor da concretização desse projeto.

TAVARES, K. M., **Previsão dos resultados do campeonato brasileiro de futebol utilizando redes neurais artificiais**. 2015. xxxxxxxxxxxxxxxx f. Monografia de Conclusão de Curso (Bacharel), Universidade Federal de Uberlândia, Uberlândia.

## RESUMO

Prever resultados de jogos de futebol é uma tarefa árdua e por vezes dita impossível. Os resultados são altamente instáveis e abordagens estatísticas tem sua efetividade limitada. Tendo isso em vista, o objetivo desse trabalho foi a idealização de um sistema de predição de resultados tendo como base redes neurais artificiais, cujo uso visa eliminar dois problemas da predição de jogos de futebol: A limitação dos métodos estatísticos, ao se utilizar reconhecimento de padrões; e a eliminação de resultados tendenciosos, ao se usar exclusivamente dados concretos de resultados históricos. A linguagem de programação orientada a objetos Java foi utilizada para a montagem da rede neural artificial desse projeto, a qual consiste de um perceptron multicamadas utilizando a regra de treinamento supervisionado de Backpropagation. Dois conjuntos de dados de entrada foram considerados, um visando exprimir o histórico recente dos times e o outro visando exprimir sua estabilidade e constância. Por fim, os resultados foram validados de forma a excluir alguns palpites menos confiáveis, garantindo assim uma taxa de acerto mais elevada nos restantes.

*Palavras Chave: Inteligência Artificial, Redes Neurais Artificiais, Backpropagation, Futebol, Predição.*

TAVARES, K. M., **Prediction of the Brazilian soccer championship results using artificial neural networks** 2015. xxxxxxxxxxxxxxxx f. Monografia de Conclusão de Curso (Bacharel), Universidade Federal de Uberlândia, Uberlândia.

## ABSTRACT

The result prediction of soccer games is an arduous task and sometimes said to be impossible. The results are highly unstable and statistical approaches have their effectivity limited. With this in mind, the goal of this work was the idealization of a result prediction system based on artificial neural networks, the use of which aims to eliminate two problems of the soccer games prediction: The limitation of statistical methods, when using pattern recognition; and the elimination of biased results, when using only concrete data from historical results. The object oriented programming language Java was used to assemble the artificial neural network of this project, which consists of a multilayer perceptron using the supervised Backpropagation training rule. Two sets of input data were considered, one seeking to express the recent history of the teams and the other seeking to express their stability and constancy. Finally, the results were validated to exclude some less reliable predictions, thus ensuring a higher success ratio on the others.

*Keywords: Artificial Intelligence, Artificial Neural Networks, Backpropagation, Soccer, Prediction.*

## Lista de Figuras

2.1	Modelo completo de um neurônio (HAYKIN, 1999a) . . . . .	6
2.2	Neurônio de McCulloch-Pitts (FAUSSET, 1994) . . . . .	7
2.3	Bias "b"em uma RNA . . . . .	8
2.4	Fronteira e Regiões de decisão para a função lógica <i>OU</i> (FAUSSET, 1994) . . .	8
2.5	RNA para a função lógica <i>E</i> . . . . .	12
2.6	RNA resolvida para a função lógica <i>E</i> . . . . .	14

## Lista de Tabelas

2.1	Tabela Verdade para a função lógica E . . . . .	12
2.2	Variação dos pesos para o primeiro par de entradas . . . . .	12
2.3	Variação dos pesos para o segundo par de entradas . . . . .	13
2.4	Variação dos pesos para o terceiro par de entradas . . . . .	13
2.5	Variação dos pesos para o quarto par de entradas . . . . .	13



## Lista de Símbolos

<i>RNA</i>	- Rede Neural Artificial
<i>POO</i>	- Programação Orientada a Objetos
<i>IA</i>	- Inteligência Artificial
<i>NI</i>	- Neurônio Intermediário
<i>IDE</i>	- Integrated Development Environment; Ambientes de Desenvolvimento Integrado
<i>GUI</i>	- Graphical User Interface; Interface Gráfica do Utilizador
<i>API</i>	- Application Programming Interface; Interface de Programação de Aplicações
<i>UFU</i>	- Universidade Federal de Uberlândia
<i>FEMEC</i>	- Faculdade de Engenharia Mecânica
$\alpha$	- Taxa de aprendizado
$P$	- Probabilidade do neurônio de saída
$\sigma$	- Desvio padrão das probabilidades dos neurônios de saída

## SUMÁRIO

<b>1</b>	<b>INTRODUÇÃO</b>	<b>2</b>
1.1	Objetivos . . . . .	3
1.2	Justificativa . . . . .	4
<b>2</b>	<b>FUNDAMENTAÇÃO TEÓRICA</b>	<b>5</b>
2.1	Redes Neurais Artificiais . . . . .	5
2.1.1	McCulloch-Pitts . . . . .	6
2.1.2	Bias . . . . .	7
2.1.3	Separabilidade Linear . . . . .	8
2.1.4	Representação dos dados . . . . .	9
2.1.5	Aprendizado de Hebb . . . . .	10
2.1.6	Técnica de aprendizado . . . . .	11

# CAPÍTULO I

## INTRODUÇÃO

O trabalho com redes neurais artificiais, também referidas simplesmente como RNA, foi motivado desde a sua criação pelo reconhecimento de que o cérebro humano processa informações de uma maneira completamente diferente dos computadores digitais modernos. O cérebro é um sistema altamente complexo, não linear e que processa paralelamente suas informações. Possui também a capacidade de organizar seus elementos estruturais, conhecidos como neurônios, de forma a realizar certas tarefas (e.g., reconhecimento de padrões, percepção e controle motor) (HAYKIN, 1999a).

Para alcançar uma boa performance, redes neurais empregam uma interconexão massiva de células computacionais simples, que são referenciadas como "neurônios" ou "unidades de processamento". Segundo HAYKIN (1999a) uma rede neural é um processador com distribuição paralela massiva, feito de unidades de processamento simples, as quais possuem uma propensão natural para armazenar conhecimento experimental e torná-lo disponível para uso.

Redes Neurais são ferramentas úteis para a resolução de diversos problemas, os quais podem ser caracterizados como mapeamento (incluindo associação e classificação de padrões), agrupamento, e otimização restrita. Existem diversas redes neurais disponíveis para cada tipo de problema (FAUSSET, 1994). Pela perspectiva de reconhecimento de padrões, redes neurais podem ser consideradas como uma extensão das muitas técnicas convencionais que vêm sendo desenvolvidas ao longo de várias décadas (BISHOP, 1995).

O futebol, por sua vez, tem sido desde a sua criação (no século XIX pelos ingleses)

um dos esportes mais conhecidos e jogados pelo mundo. Há muito, vários países (principalmente Europeus e Sul-americanos) já fizeram do futebol o seu esporte mais popular (SILVA et al., 2002).

O futebol brasileiro é mundialmente conhecido por sua qualidade e pela paixão que os brasileiros sentem pelo esporte. Segundo DA COSTA (2005), o esporte é praticado por aproximadamente 30 milhões de brasileiros e possui 102 milhões de torcedores apenas dentre os 16 maiores clubes (em termos de tamanho de torcida).

Um fato bastante aceito entre os amantes do futebol diz respeito à imprevisibilidade dos resultados das partidas. Os jogos são disputados entre dois times e podem terminar com vitória do time da casa, vitória do time visitante e empate. Para a determinação do resultado de uma partida, encontram-se fatores esperados e imprevistos, ambos os quais têm influência no resultado da disputa (ASLAN e INCEOGLU, 2007).

A abordagem estatística para previsão de resultados já é bastante utilizada e seu aprimoramento já foi bastante estudado, como pode ser visto em ELO e SLOAN (2008), MEHREZ e HU (1995) e SILVA et al. (2002). Apesar dos esforços e estudos, a assertividade desses métodos ainda não chegou a ultrapassar a taxa de 50%.

Por sua vez, as RNAs têm se mostrado uma ferramenta muito poderosa para modelagem matemática, tanto em pesquisas quanto em aplicações práticas. Elas podem efetuar mapeamentos entre espaços de entrada e saída altamente não lineares. Com sua abordagem não-paramétrica, faz-se desnecessária a análise funcional da forma de distribuição dos dados. Assim sendo, se mostram uma ferramenta com grande potencial para a previsão dos resultados de partidas de futebol (CHENG et al., 2003).

## 1.1 Objetivos

O objetivo geral desse trabalho é desenvolver um programa em Java, capaz de utilizar a técnica de RNAs para realizar a previsão do resultado de uma partida do Campeonato Brasileiro de Futebol.

Os objetivos específicos são:

- Estudar sistemas computacionais estruturados em Redes Neurais Artificiais;

- Estudar a linguagem de programação Java, usada como base para a criação do algoritmo da RNA;
- Estudar dados de partidas de futebol e encontrar informações relevantes que influenciem o resultado das mesmas;
- Criação de um banco de dados estruturado e versátil com os dados de partidas passadas;
- Desenvolvimento do software responsável pela análise e tratamento dos dados e fornecimento dos resultados;
- Análise profunda de dados e da topologia da RNA criada, de forma a otimizar o seu funcionamento.

## 1.2 Justificativa

O resultado das partidas de futebol é hoje um fator ainda imprevisível. Os estudos já realizados para prever o desfecho de um jogo utilizam quase que exclusivamente métodos estatísticos. Estes por sua vez, apesar das diversas técnicas e abordagens já utilizadas, ainda não conseguiram acertar mais da metade dos resultados. Existem alguns poucos estudos com abordagens híbridas, utilizando estatística e redes neurais artificiais, os quais fornecem uma melhor taxa de acerto. Contudo, essa taxa ainda é baixa e gira em torno de 50%.

A proposta de utilizar somente redes neurais e reconhecimento de padrões é inovadora e promissora. Abdicando dos recursos estatísticos tem-se uma liberdade maior para o reconhecimento de anomalias, que outrora seriam tratadas como ruídos. A instabilidade da relação dados-resultados causada pelos mais diversos fatores do ambiente futebolístico, pode ser contornada pela capacidade inata das redes neurais de mapeamento, percepção e reconhecimento de padrões.

Apesar de o futebol ser o esporte mais seguido no Brasil, estudos de previsão de resultados utilizando dados de jogos disputados com times do Brasil são desconhecidos. O uso inovador de redes neurais e a utilização de dados do Campeonato Brasileiro são, portanto, inéditos. Deste modo, nos deparamos com um campo de estudos promissor e ainda não explorado.

# CAPÍTULO II

## FUNDAMENTAÇÃO TEÓRICA

Este capítulo trata de alguns assuntos importantes para a compreensão do trabalho, tais como: Redes Neurais Artificiais, Perceptrons, Adaline, Madaline, Regra Delta, funções de ativação, camadas intermediárias, algoritmos de treinamento, Backpropagation, programação orientada a objetos e Java.

### 2.1 Redes Neurais Artificiais

Toda a base para a realização desse trabalho se encontra no uso uma rede neural artificial (RNA), adequada para a realização do reconhecimento de padrões entre condições anteriores às partidas e o resultado das mesmas. Uma RNA é um sistema de processamento de informações que possui algumas características em comum com redes neurais biológicas. O desenvolvimento da teoria de redes neurais artificiais ocorreu a partir de generalizações matemáticas de modelos de percepção humana. LAURENE FAUSETT. Para isso, algumas hipóteses são levadas em conta: Assume-se que o processamento de informações ocorre em vários elementos simples chamados neurônios; Sinais são passados entre neurônios através de uma conexão; Cada conexão possui um peso associado, o qual, em redes neurais artificiais típicas, multiplicam o sinal transmitido; Cada neurônio possui uma função de ativação, a qual determina o sinal de saída com base na soma dos sinais de entrada. Um modelo completo de um neurônio, com base nas hipóteses acima, está mostrado na Figura 2.1.

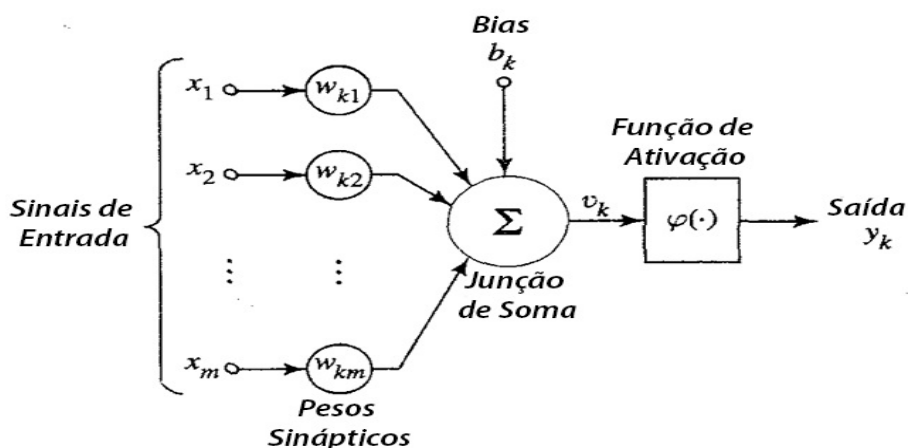


Figura 2.1 – Modelo completo de um neurônio (HAYKIN, 1999a)

### 2.1.1 McCulloch-Pitts

O primeiro modelo de neurônio artificial foi concebido por Warren McCulloth e Walter Pitts (MCCULLOTH e PITTS, 1943). Algumas das regras de funcionamento desses neurônios são aplicadas ainda hoje nas redes neurais modernas. Podemos descrever as regras que permeiam o funcionamento dos mesmos com base nas seguintes definições:

- A ativação do neurônio é binária. Ou seja, para cada situação de entrada existem apenas duas saídas, ativado ou desativado;
- Os neurônios são conectados diretamente por ligações, que possuem seu respectivo peso único;
- Uma ligação é excitatória se seu peso é positivo, e inibitória se seu peso é negativo. Todas conexões excitatórias possuem o mesmo peso;
- Cada neurônio possui um valor limiar, e sua ativação é função da soma dos pesos de entrada (excitatórios e inibitórios). A ativação ocorre quando a soma dos pesos ultrapassa o valor limiar;
- A definição do limiar ocorre de forma que qualquer entrada não inibitória diferente de zero faça com que o neurônio não seja ativado;
- É necessário um passo temporal para que o sinal passe por um link da conexão.




Figura 2.2 – Neurônio de McCulloch-Pitts (FAUSSET, 1994)

Um modelo completo de um neurônio, segundo as definições acima, é mostrado na Figura 2.2.

A função de ativação (degrau) desse neurônio é dado segunda a Equação 2.1, onde  $Y_{in}$  é a soma das entradas de cada um dos neurônios, conforme Equação 2.2. O limiar do neurônio é dado pela Equação 2.3.

$$f(y_{in}) = \begin{cases} 1 & \text{se } Y_{in} > \theta \\ 0 & \text{se } Y_{in} \leq \theta \end{cases} \quad (2.1)$$

$$Y_{in} = n \cdot w + m \cdot p \quad (2.2)$$

$$\theta = n \cdot w - p \quad (2.3)$$

### 2.1.2 Bias

O uso de um limiar para definir a ativação do neurônio pode ser substituído pelo uso de um bias. O bias age exatamente como o peso de uma conexão cuja entrada é sempre 1 (FAUSSET, 1994), conforme mostrado na Figura 2.3.

O uso do bias ou do limiar são equivalentes. Sua importância se mostra durante a análise da separabilidade linear de um problema, conforme mostrado na Subseção 2.1.3, e durante a análise de convergência do erro, não tratada nesse trabalho.






Figura 2.3 – Bias "b" em uma RNA

A diferença de aplicação entre as duas técnicas é dada pela função de ativação do neurônio, que com o uso do bias fica escrita conforme a Equação 2.4.

$$f(y_{in}) = \begin{cases} 1 & \text{se } Y_{in} > 0 \\ 0 & \text{se } Y_{in} \leq 0 \end{cases} \quad (2.4)$$

### 2.1.3 Separabilidade Linear

Para uma determinada rede, a resposta está confinada entre dois valores (1 ou 0, sim ou não, -1 ou 1, etc...). Existe uma fronteira, chamada *fronteira de decisão* Figura 2.4 que delimitada as regiões em que a resposta assume um ou outro valor.

A Equação 2.5 mostra a relação que determina essa fronteira para funções de ativação do tipo degrau. Dependendo do número de entradas na rede, essa equação pode representar uma linha, um plano ou um hiperplano.

$$b + \sum_i x_i \cdot w_i = 0 \quad (2.5)$$

Diz-se que um problema é linearmente separável caso existam pesos (e bias) suficientes para que todos vetores de entrada do conjunto de treinamento sejam separados pela fronteira de decisão em dois grupos, de forma que os vetores cujas saídas sejam positivas fiquem todos em um grupo, e os vetores com saídas negativas fiquem em outro. Essas duas regiões são geralmente




Figura 2.4 – Fronteira e Regiões de decisão para a função lógica *OU* (FAUSSET, 1994)

chamadas de *regiões de decisão* (Figura 2.4).

MINSKY e PAPERT (1969) mostraram que problemas não linearmente separáveis, são impossíveis de serem resolvidos por redes de apenas uma camada. É possível demonstrar também que redes de várias camadas, com funções de ativação lineares, também são incapazes de resolver tais problemas.

A inclusão de um bias pode transformar um problema linearmente inseparável (e portanto incapaz de ser resolvido com os métodos já apresentados) em um problema que pode ser resolvido. Isso é possível graças a adição de uma nova conexão de entrada, que será usada como valor constante para o bias. Essa nova conexão aumenta o conjunto de entradas, fornecendo mais um grau de liberdade para a rede.

#### 2.1.4 Representação dos dados

No início dos estudos de redes neurais, a representação de dados se dava na forma binária, ou seja, utilizando 1 para reforço positivo e 0 para reforço negativo. Essa representação inicial não é, de modo geral, recomendada.

A forma bipolar é uma alternativa bastante eficiente. Essa representação utiliza 1 para reforço positivo e -1 para reforço negativo. Assim como a inclusão de um bias, a simples mudança da representação de dados para a forma bipolar pode transformar um problema sem solução em um problema que pode ser resolvido.

Caso o problema proposto requeira da rede uma generalização dos dados de entrada, o uso da forma bipolar é altamente indicado. A representação bipolar permite que dados não disponíveis sejam adotados com valor 0 de entrada, não fornecendo assim reforço positivo ou negativo.

Ao contrário do que acontece na forma binária, a representação bipolar também é mais eficiente do ponto de vista do treinamento. Por exemplo, em uma rede treinada pelo método de Hebb (Subseção 2.1.5), para conjuntos de sinais entrada cujo resultado da rede seja negativo (0 para binário ou -1 para bipolar), o uso da primeira representação impossibilita completamente um aprendizado da rede.

#### 2.1.5 *Aprendizado de Hebb*

Das regras de treinamento de redes neurais, a regra de Hebb é a mais antiga, mais simples e mais conhecida de todas. Hebb propôs seu método de treinamento tendo como base um contexto neurobiológico. STENT (1973) e CHANGEUX e DANCHIN (1976) reescreveram o pensamento de Hebb de uma forma mais simples e concisa, como se segue:

- Se dois neurônios em ambos os lados de uma sinapse (conexão) são ativados simultaneamente (i.e. de forma síncrona), então a força dessa sinapse é seletivamente aumentada.
- Se dois neurônios em ambos lados de uma sinapse são ativados de forma assíncrona, então essa sinapse é seletivamente enfraquecida ou eliminada.

A afirmação original de Hebb não incluía a segunda parte. Da mesma forma, ela também comentava apenas a respeito de neurônios sendo ativados ao mesmo tempo.

McCLELLAND e RUMELHART (1988) estenderam a regra de Hebb para que o reforço positivo da sinapse também ocorra caso os neurônios sejam ambos desativados simultaneamente. Podemos, então, complementar o pensamento anterior:

- Se dois neurônios em ambos os lados de uma sinapse são DESATIVADOS simultaneamente, então a força dessa sinapse é seletivamente aumentada.

Estamos considerando inicialmente redes de apenas uma camada, onde cada conexão possui, em cada lado, apenas um neurônio de entrada e um neurônio de saída. O valor do neurônio

de entrada  $X$  é multiplicado pelo peso  $W$  dessa conexão para se obter o valor do neurônio de saída  $Y$ . Seguindo essa nomenclatura e representando os dados na forma bipolar, podemos representar a atualização do peso pela regra de Hebb segundo a Equação 2.6.

$$\Delta w_{ij} = x_i \cdot y_i \quad (2.6)$$

Se utilizarmos a representação binária, essa equação não distingue conexões que possuem uma entrada "positiva" e uma saída "negativa" de conexões onde tanto a entrada quanto a saída são "negativas". Essa é uma das vantagens mais facilmente observáveis da utilização de dados bipolares (ao invés de binários) para a representação dos dados.

#### 2.1.6 Técnica de aprendizado

Existem várias técnicas de implementação das regras de aprendizado existentes. A técnica abordada aqui nada mais é do que uma das formas mais simples e genéricas de se aplicar a regra de Hebb. O entendimento dessa técnica é crucial para a posterior compreensão das outras técnicas aplicadas nesse trabalho, que podem ser tomadas como simples variações mais elaboradas desta.

O aprendizado é dado na forma iterativa e segue o seguinte algoritmo:

1. Os pesos de todas as conexões são inicializados com o valor 0.
2. Para todos os conjuntos de entradas e saídas, repetem-se os passos 3-4.
3. Para cada conexão, calculamos a variação do seu respectivo peso pela equação 6.
4. Cada peso é atualizado conforme calculado no passo 3.

Para esclarecer um pouco mais o algoritmo acima mostrado, segue um exemplo de sua aplicação em uma rede real com representação bipolar, onde usaremos como parâmetros de entrada a função lógica E. Buscaremos com essa rede descobrir os valores dos pesos das conexões que determinam a fronteira de decisão dessa função.

A função lógica E retorna um valor "positivo" apenas se ambas as entradas possuírem também um valor "positivo". Assim sendo, montaremos a tabela verdade dessa função conforme a Tabela 2.1. A representação gráfica dessa rede está mostrada na Figura 2.5.

Tabela 2.1 – Tabela Verdade para a função lógica E

Bias	Entradas		Saída
	$X_1$	$X_2$	Y
1	1	1	1
1	1	-1	-1
1	-1	1	-1
1	-1	-1	-1




Figura 2.5 – RNA para a função lógica E

Iniciamos o treinamento conforme o passo 1 do algoritmo. Fazemos então os valores de  $w_0 = 0$ ,  $w_1 = 0$  e  $w_2 = 0$ .

Utilizaremos o primeiro par de entradas (1,1). Assim, calculamos o valor da variação dos pesos conforme a Equação 2.6. O resultado é mostrado na Tabela 2.2.

Tabela 2.2 – Variação dos pesos para o primeiro par de entradas

1	Entrada		Saída desejada	Variação dos pesos ( $\Delta w$ )		
	$X_1$	$X_2$		$\Delta w_0$	$\Delta w_1$	$\Delta w_2$
1	1	1	1	1	1	1

Na sequência, atualizamos os pesos com os resultados da Equação 2.7.

$$\begin{cases} w_0 = 0 + \Delta w_0 = 1 \\ w_1 = 0 + \Delta w_1 = 1 \\ w_2 = 0 + \Delta w_2 = 1 \end{cases} \quad (2.7)$$

Repetimos o procedimento para o segundo par de entradas (1, -1). Assim, calculamos o valor da variação dos pesos conforme a Equação 2.6. O resultado é mostrado na Tabela 2.3.

Tabela 2.3 – Variação dos pesos para o segundo par de entradas

	Entrada		Saída desejada Y	Variação dos pesos ( $\Delta w$ )		
	$X_1$	$X_2$		$\Delta w_0$	$\Delta w_1$	$\Delta w_2$
1	1	-1	-1	-1	-1	1

Na sequência, atualizamos os pesos com os resultados da Equação 2.8.

$$\begin{cases} w_0 = 1 + \Delta w_0 = 0 \\ w_1 = 1 + \Delta w_1 = 0 \\ w_2 = 1 + \Delta w_2 = 2 \end{cases} \quad (2.8)$$

Repetimos o procedimento para o terceiro par de entradas (-1, 1). Calculamos o valor da variação dos pesos conforme a Equação 2.6. O resultado é mostrado na Tabela 2.4.

Tabela 2.4 – Variação dos pesos para o terceiro par de entradas

	Entrada		Saída desejada Y	Variação dos pesos ( $\Delta w$ )		
	$X_1$	$X_2$		$\Delta w_0$	$\Delta w_1$	$\Delta w_2$
1	-1	1	-1	-1	1	-1

Na sequência, atualizamos os pesos com os resultados da Equação 2.9.

$$\begin{cases} w_0 = 0 + \Delta w_0 = -1 \\ w_1 = 0 + \Delta w_1 = 1 \\ w_2 = 2 + \Delta w_2 = 1 \end{cases} \quad (2.9)$$

Repetimos uma última vez o procedimento para o quarto par de entradas (-1, -1).

Calculamos o valor da variação dos pesos conforme a Equação 2.6. O resultado é mostrado na Tabela 2.5.

Tabela 2.5 – Variação dos pesos para o quarto par de entradas

	Entrada		Saída desejada	Variação dos pesos ( $\Delta w$ )		
	$X_1$	$X_2$		$\Delta w_0$	$\Delta w_1$	$\Delta w_2$
1	-1	-1	-1	-1	1	1

Na sequência, atualizamos os pesos com os resultados da Equação 2.10.

$$\begin{cases} w_0 = -1 + \Delta w_0 = -2 \\ w_1 = 1 + \Delta w_1 = 2 \\ w_2 = 1 + \Delta w_2 = 2 \end{cases} \quad (2.10)$$

Terminamos assim o treinamento e a rede resultante é mostrada na Figura 2.6.




Figura 2.6 – RNA resolvida para a função lógica  $E$

## Referências Bibliográficas

- S. R. ALPERT, S. W. WOYAK, H. J. SHROBE, and L. F. ARROWOOD. Guest editor's introduction: Object-oriented programming in ai. *IEEE Expert: Intelligent Systems and Their Applications*, 5:6–7, 12 1990.
- B. G. ASLAN and M. M. INCEOGLU. A comparative study on neural network based soccer result prediction. In *Seventh International Conference on Intelligent Systems Design and Applications*. IEE Computer Society, 2007.
- C. M. BISHOP. *Neural Networks for Pattern Recognition*. Clarendon Press, 1995.
- J. P. CHANGEUX and A. DANCHIN. Selective stabilization of developing synapses as a mechanism for the specification of neuronal networks. *Nature*, 264:705–712, 1976.
- T. CHENG, D. CUI, Z. FAN, J. ZHOU, and S. LU. A new model to forecast the results of matches based on hybrid neural networks in the soccer rating system. In *Fifth International Conference on Computational Intelligence and Multimedia Application*. IEE Computer Society, 2003.
- L. P. DA COSTA. *Atlas do esporte no Brasil: Atlas do esporte, educação física e atividades de saúde e lazer no Brasil*. Shape Editora e Promoções Ltda., 2005.
- A. E. ELO and S. SLOAN. *The Rating of Chess Players, Past and Present*. Ishi Press International, 2008.
- L. V. FAUSSET. *Fundamentals of Neural Networks: Architectures, Algorithms, and Applications*. Prentice-Hall, 1994.



- A. M. FLITMAN. Towards probabilistic footy tipping: a hybrid approach utilising genetically defined neural networks and linear programming. *Computers & Operations Research*, 33:2003–2022, 7 2006.
- S. S. HAYKIN. *Neural Networks: A Comprehensive Foundation*. Prentice Hall, second edition, 1999a.
- S. S. HAYKIN. *Neural Networks and Learning Machines*. Prentice Hall, third edition, 1999b.
- J. L. McCLELLAND and D. E. RUMELHART. *Explorations in Parallel Distributed Processing*. Cambridge, MA: MIT Press, 1988.
- W. S. MCCULLOTH and W. PITTS. A logical calculus of the ideas immanent in nervous activity. *Bulletin of Mathematical Biophysics*, 5:115–133, 1943.
- A. MEHREZ and M. Y. HU. Predictors of the outcome of a soccer game - a normative analysis illustrated for the israeli soccer league. *Zeitschrift für Operations Research*, 42:361–372, 10 1995.
- W. T. MINSKY and S. A. PAPERT. *Perceptrons, Expanded Edition*. Cambridge, MA: MIT Press, 1969.
- M. C. PURUCKER. Neural network quarterbacking: How different training methods perform in calling the games. *Potentials, IEEE*, 15:9–15, 8 1996.
- C. F. SILVA, E. S. GARCIA, and E. SALIBY. Soccer championship analysis using monte carlo simulation. In *2002 Winter Simulation Conference*, volume 1-2, pages 2011–2016, 2002.
- G. S. STENT. A physiological mechanism for hebb's postulate of learning. *Proceedings of the National Academy of Science of the U.S.A.*, 70:997–1001, 1973.
- M. WATSON. *Practical Artificial Intelligence Programming With Java*. Mark Watson, third edition, 2008.